FabricSandbox v2

GPU 通信网络规划与故障分析

课程：数据通信网络 MAiNS

成员：熊宇琛 马贤纯 王忻晔

路线：GPT-2 Small DDP 训练主线 + Qwen2.5-7B TP 推理第二案例

交付概览	结果
自动化测试	180 / 180 通过（178 基线 + 2 项整合证据）
DDP 仿真复现	19 / 19 情景 PASS
TP 第二案例	9 / 9 代表场景 PASS；6 / 6 扩展实验完成
真实 GPU	2 × RTX 3090；profile 与 AllReduce 已完成
网页与持久化	真实 HTTP、浏览器、重启验收通过

本报告的实测数值来自 A 的 RTX 3090 测量；网络、检查点和 Qwen 推理性能仍主要来自 SYNTHETIC 仿真，正文逐项区分。

1 问题与系统边界

目标是解释给定模型工作负载、GPU 放置、网络容量与故障轨迹如何共同决定作业和请求结局。系统采用事件驱动流级仿真，不执行真实神经网络，也不等同于在线 GPU 集群。

输入	计算过程	输出
模型 profile、拓扑、任务/请求、故障、horizon	成组准入、路径选择、共享容量更新、状态机、通信和检查点事件	完成/等待/拒绝/失败终态、事件、资源曲线、约束检查、只读解释

数据来源分三类

来源	本报告中的用途	解释限制
MEASURED	GPT-2 单卡前后向、优化器、显存与两卡 AllReduce	只对应记录中的 GPU、软件与消息大小
DERIVED	参数、梯度、Ring 字节量、KV 公式	描述结构关系，不是硬件耗时
SYNTHETIC	网络、计算回填后的部分恢复、Qwen profile	用于条件分析，不代表真实集群性能

两个案例

	案例 1：DDP	案例 2：TP
模型	GPT-2 Small	Qwen2.5-7B-Instruct
关键数据	FP32 梯度	层内激活与 KV cache
核心状态	Job、步、检查点、epoch	Replica、Request、prefill/decode

2 系统架构与模块边界

应用层负责提交、权限和展示；领域层决定通信与业务状态；公共资源内核只管理路径、活动流、容量和事件。DDP 与 TP 场景共享同一个资源账本。

工作负载页面 → Gateway / 权限 → SimulationService → SQLite

↓

DDP / TP adapter → Network / Engine / Ring → 事件 / 指标 / 容量证据

组件	职责	明确边界
apps/web/workload.html	输入、指标、时间线、容量曲线、解释展示	事件为完成后回放，不是实时 GPU 监控
Gateway	提交、查询、事件分页、权限、只读解释	服务级共享角色，无个人账户和租户隔离
SimulationService	冻结输入、异步单 worker、SQLite	不提供持久执行队列或自动续跑
fabric_sim/ddp.py	训练步、成组准入、检查点、故障恢复	固定 world size，无弹性缩卡
fabric_sim/tp.py	TP 合法性、KV 准入、请求与副本状态	每副本单请求，无连续批处理
fabric_sim/core.py	方向资源、共享容量、传输和 Ring	无完整交换机图、ECMP 或自动绕路

旧 static planner、aggregator 与 NATS worker 仅保留为兼容骨架，未进入 v2 主执行链。

3 数据与行为合同

SimulationSpec 在提交时冻结并生成 canonical input_hash；每个 SimulationRun 保存原输入、状态和结果。编辑草稿不会改变已有运行。

对象	关键字段	语义
SimulationSpec	scenario、topology、jobs/requests、faults、horizon_ms	不可变输入
SimulationRun	id、status、input_hash、timestamps	queued/running/completed/failed/interrupted
DDP Job	world_size、steps、checkpoint_interval、gpu_ids	固定通信组与训练进度
TP Replica	tp_size、gpu_ids、memory_gib	权重分片与副本合法性
TP Request	arrival_ms、prompt_tokens、max_new_tokens	排队、prefill、decode、终态
Event / Result	time_ms、kind、subject_id、metrics、checks	支持回放与诊断

服务完成不等于业务成功

completed 仅表示仿真程序结束；作业仍可能是 unschedulable，请求仍可能是 rejected 或 failed。故障、等待、拒绝和回滚必须在独立状态字段中解释。

重启语义

已完成记录继续可读；服务重启前仍为 queued/running 的运行标记为 interrupted，不自动续跑。

4 案例 1：DDP 模型、实测与通信

GPT-2 Small 固定为 12 层、hidden=768、12 个注意力头、FFN=3072、词表 50257、最大位置 1024。词嵌入与输出头共享权重。

量	数值	来源
参数量	124,439,808	DERIVED
FP32 梯度	497,759,232 bytes	DERIVED
单卡前向+反向中位数	34.487 ms	MEASURED
优化器中位数	15.213 ms	MEASURED
峰值 reserved / 准入预算	2.561 GiB / 3.561 GiB	MEASURED + 1 GiB 策略余量
两卡 AllReduce 中位数	83.206 ms, 5.982 GB/s	MEASURED, 20 samples

计算和通信依赖

阶段	行为	约束
前向 / 反向	每 rank 处理不同 batch	每卡保存完整模型与优化器状态
ReduceScatter	R−1 轮	块大小 D/R；轮间屏障
AllGather	R−1 轮	全部轮次完成后才可更新
Optimizer / Step	各 rank 独立更新相同参数	同步完成前不得提交下一步

A 的两卡测量只验证指定梯度张量的 NCCL AllReduce，不强制 Ring 算法；单卡 profile 与独立 AllReduce 不可相加冒充真实多卡 DDP 步时。

5 案例 1：复现、竞争与准入结果

B 在 Windows/Python 3.12.10 上复跑 19 个场景，全部
PASS；metrics、链路曲线和竞争表与原基线逐字节一致。A、B 的实现 hash 均为 d8447344…。

实验	结果	解释
E0 Ring	8.053064 ms	4 rank、64 MiB、零延迟；6 轮与解析值一致
D1 compact	5343.733 ms	两个作业分别位于不同机架，无共享上联
D2 A 独占	7137.466 ms	跨机架 spread 放置
D2 A+B 并发	10721.333 ms	同放置，TTFT 竞争为 1.502 倍
D3 成组准入	C 等待 4743.742 ms	不部分占卡；B 完成后 C 获得 4 张 GPU
D4 故障无备用	A 丢失 6 步	回滚第 10 步，保持 world size=4
D4 保存中故障	A 丢失 10 步	未提交检查点不能用于恢复

A 将实测 compute_ms、optimizer_ms 与 admission memory 回填后，compact 与 competition 分别完成 30 步，仿真时间为 3684.744 ms 与 9062.344 ms。网络、检查点和恢复时间仍是 SYNTHETIC，因此这两组不是纯 GPU 训练实测。

B 的扩展实验：上联 25 / 50 / 100 Gbps 时完成时间为 17889.07 / 10721.33 / 7137.47 ms；每作业 10 / 20 / 30 / 40 步时事件数约线性增长，结果大小从 1.28 MB 到 5.10 MB。

6 DDP 状态机、检查点与反例

等待 → 计算 → Ring 同步 → 更新 / 检查点 → 完成。故障发生后停止整组，回滚到上一份已提交检查点，再按原 world size 重新准入。

反例	错误做法	正确语义
运行中损失一张卡	保留健康卡缩为小 world size	整组中止，释放健康卡，等待完整四卡
检查点保存到一半故障	使用正在保存的步数恢复	回滚上一份已提交检查点
故障前完成事件晚到	推进新 epoch 的训练步	event_epoch 守卫后忽略
没有备用卡	立即判永久失败	暂时等待资源；永久规格不足才 unschedulable

关键证据

有备用：A 从第 16 步回滚第 10 步，丢失 6 步，400 ms 后恢复；无备用：A 额外等待 2343.733 ms，待 B 完成后恢复；保存中故障：1747.911 ms 故障，回滚第 0 步，丢失 10 步；旧保存事件被忽略。

B 对事件逐条重放后确认：GPU 从未被两个作业同时占用；故障后未再分配 n0；每步 epoch 与当时作业 epoch 一致；结束时无残留占用。

7 案例 2：TP 模型与 KV 准入

Qwen2.5-7B-Instruct 使用 TP=1/2/4。权重按 TP 切分；每层前向建模范式包含两次 AllReduce；每个副本一次处理一条请求。

对象	规则	异常语义
合法部署	恰好 TP 张健康 GPU，且 TP 满足注意力头约束	非法拓扑拒绝输入
权重显存	每卡保存分片权重	权重在请求结束后不释放
KV cache	按最大输入 + 最大输出静态预留	预算不足时请求 rejected
请求执行	queue → prefill → decode × N → completed	首 token 后仍须完成全部 token
副本故障	在途请求 failed，释放该请求 KV	健康副本继续，不迁移失败请求

KV 公式

KV bytes = 2 × layers × KV heads × head_dim × (prompt_tokens + max_new_tokens) × batch × element_bytes

首版采用 worst-case 静态预留。它使准入边界容易证明，但会降低显存利用率；没有实现 PagedAttention、连续批处理或 KV 迁移。

当前 Qwen 推理时间仍是 SYNTHETIC。A 提供的 7 KiB 与 896 KiB BF16 AllReduce 是 TP 消息微基准，不是 TTFT。

8 案例 2：TP 大小与共享竞争

首个请求 TTFT 用于隔离 TP 配置；双请求平均 TTFT 还包含同一副本第二个请求的排队。两种口径下当前 SYNTHETIC profile 均为 TP2 最低。

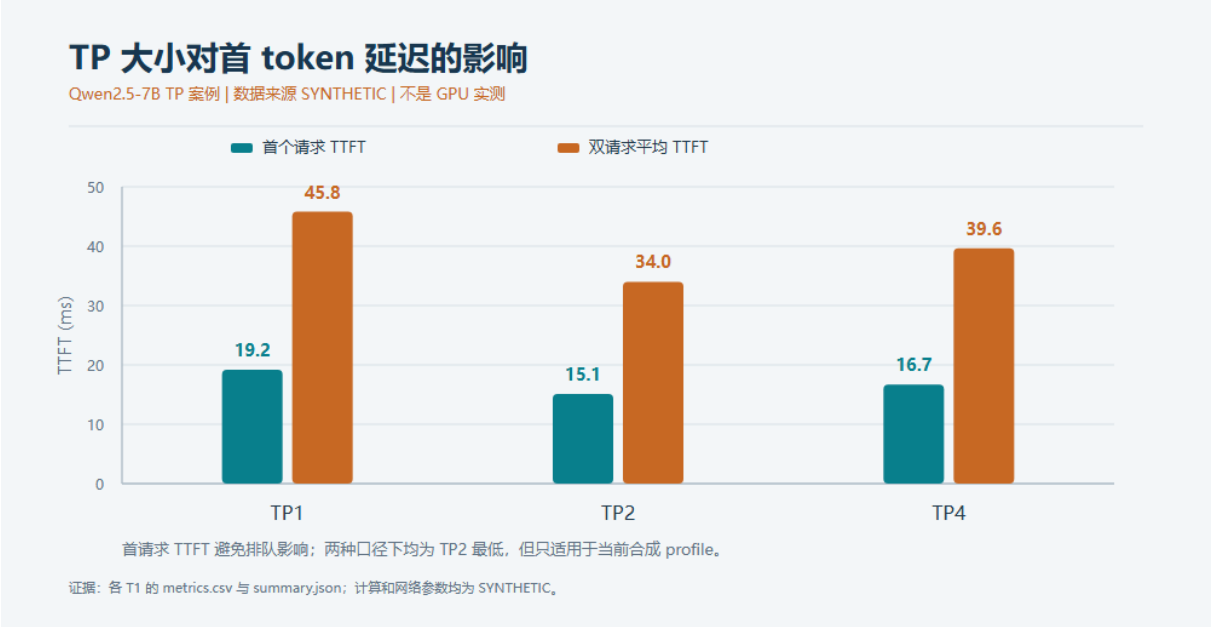


图 1：TP1/TP2/TP4 的首请求与双请求口径

配置	首个请求 TTFT	双请求平均	AllReduce 调用	KV/卡
TP1	19.200 ms	45.800 ms	0	3.84 MB
TP2	15.079 ms	34.003 ms	448	1.92 MB
TP4	16.683 ms	39.636 ms	448	0.96 MB

两副本竞争时，请求 A 的首 token 延迟由 36.061 ms 增至 44.282 ms，尾时延由 66.974 ms 增至 75.387 ms。这里保持请求、放置与 KV 准入固定，只改变另一副本是否同时通信。

TP2 最优只适用于当前合成 profile，不能外推为任意 GPU、互联或模型配置结论。

9 带宽与请求规模敏感性

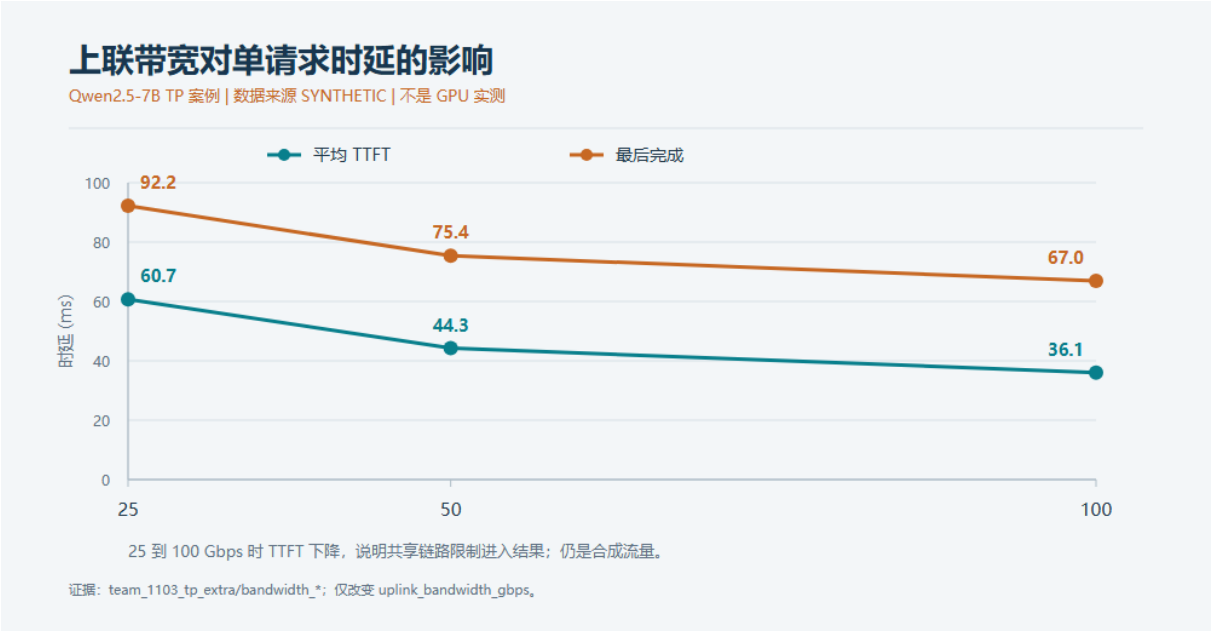


图 2：仅改变机架上联带宽，25 → 100 Gbps 时平均 TTFT 下降 40.6%

请求数	完成	平均 TTFT	最后完成	事件数	结果大小
2	2/2	44.282 ms	75.387 ms	4484	5.13 MiB
4	4/4	81.975 ms	150.774 ms	8968	10.25 MiB
8	8/8	157.362 ms	301.548 ms	17936	20.51 MiB

请求数 2 → 8 时，平均 TTFT 增长
255.4%；处理事件与结果大小近似按请求数增长。原因是单副本一次只处理一个请求。

以上是确定性事件的单次 CPU 仿真，不用于统计显著性，也不是 GPU 数量扩展性。

10 接口、权限、持久化与证据

验证范围	实际结果	证据
自动化测试	180 项通过（178 基线 + 2 项整合证据）	B 基线日志；C 整合证据测试
提交 / 查询	POST 202；completed；hash 与结果可查询	evidence/task_c_1103/http_acceptance.json
权限	匿名 401；未知 token 401；viewer 写 403；非法输入 422	HTTP 验收
快照	提交后修改客户端 JSON 不改变存储输入	stored_snapshot_not_mutated
事件 / 解释	completed_simulation_replay；解释前后结果不变	browser_acceptance.json
重启	completed 保留；running 探测变为 interrupted	restart_acceptance.json
业务终态	memory_reject 的服务为 completed，作业为 unschedulable	HTTP 验收
A/B/C 证据整合	GET /api/v2/evidence；页面显示三人摘要与实现 hash	evidence/integration_1103/provenance.json

真实 HTTP 与浏览器

Gateway 仅绑定 127.0.0.1。Edge 浏览器连接 14 个场景，实际提交 DDP/TP 场景，展示指标、状态时间线、容量曲线、约束检查和只读解释。页面顶部还读取受权限保护的 A/B/C 证据摘要，明确显示 MEASURED、SYNTHETIC 与接口验收来源。

安全边界

viewer/editor 是共享服务角色，不是个人账户或租户隔离；POST explain 是只读例外；仿真输入不会执行系统命令。事件下载和结果导出不含 bearer token。

11 结论、限制与团队贡献

主要结论

- 资源约束贯通模型与状态：DDP 整组准入、TP KV 准入和共享链路限速都由同一事件资源账本解释。
- 故障语义可验证：训练组回滚完整检查点；TP 在途请求失败且不生成幽灵 token。
- A 已完成真实 GPU 基础测量：两卡 RTX 3090 的 profile 与梯度 AllReduce；B 完成 19/19 情景复现；C 完成网页、权限、持久化、TP 第二案例和交付验证。

仍需明确的边界

- 网络是两级有效容量模型，没有完整交换机图、报文队列、ECMP 或故障自动绕路。
- DDP 是单桶 Ring、轮间屏障、无计算通信重叠；没有真实多卡训练端到端测量。
- TP 没有连续批处理、PagedAttention、KV 迁移；Qwen 推理和 TTFT 未实测。
- 共享角色没有个人账户和租户隔离；服务重启不续跑未完成任务。

团队分工

成员	负责内容	关键证据
熊宇琛	领域模型与策略；DDP/TP 语义、故障和回归	A 交付；模型表、profile、AllReduce、故障轨迹
王忻晔	拓扑、容量、放置、实验与性能权衡	B 交付；19 情景、178 项基线测试与扩展分析
马贤纯	接口、状态与权限；TP 第二案例、图表和证据整合	C 交付；浏览器截图、HTTP/重启验收、图表与报告

提交前仍需团队完成

本地交付标签为 c-delivery-20261103，指向包含全部 C 交付物的固定提交。仍需发布可访问的 Git 仓库；补最终成员贡献确认；在答辩电脑重新执行启动与视频录制。当前本地目录不能替代远程仓库。

参考资料

[1] 课程 CourseProjectGuidelines.pdf；[2] GPT-2 官方配置；[3] PyTorch DDP 文档；[4] Qwen2.5-7B-Instruct 配置；[5] Megatron-LM；[6] NVIDIA nccl-tests；[7] 本项目 evidence 与验收记录。